


# 第1回 MPC 勉強会

---

鶴原康太

November 1, 2023

# MPC のイメージ



モデル予測制御 (MPC) による軌道追従制御より

有限時間の LQR をシフトさせるイメージ

# MPC 概略

## MPC で解く問題

$$x_{k+1} = Ax_k + Bu_k$$

$$J = \frac{1}{2} [x_N^T P x_N] + \frac{1}{2} \sum_{i=0}^{N-1} [x_i^T Q x_i + u_i^T R u_i]$$

終端コスト

ステージコスト

$$U = \begin{bmatrix} u_0 & u_1 & \dots & u_{N-1} \end{bmatrix}^T$$

- 1.  $J$  が最小になるような  $u_0^* \sim u_{N-1}^*$  を求める
  - 1.1 既知変数  $x_0$  から未知変数  $x_1 \sim x_N$  を推定
  - 1.2  $U$  についての最適化問題に変形
  - 1.3 最適化問題を解く
2.  $u_0^*$  をシステムへの入力とする

# 未知変数 $x_1 \sim x_N$ を推定 ( $x_0$ は現在の状態)

行列形式:

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} = \begin{bmatrix} A \\ A^2 \\ \vdots \\ A^N \end{bmatrix} x_0 + \begin{bmatrix} B & 0 & \dots & 0 \\ AB & B & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N-1}B & A^{N-2}B & \dots & B \end{bmatrix} \begin{bmatrix} u_0 \\ u_1 \\ \vdots \\ u_{N-1} \end{bmatrix}$$

- 1 ステップ先の予測:

$$x_1 = Ax_0 + Bu_0$$

- 2 ステップ先の予測:

$$\begin{aligned} x_2 &= A(Ax_0 + Bu_0) + Bu_1 \\ &= A^2x_0 + ABu_0 + Bu_1 \end{aligned}$$

- 一般的に  $N$  ステップ先の予測:

$$x_N = A^Nx_0 + A^{N-1}Bu_0 + A^{N-2}Bu_1 + \dots + Bu_{N-1}$$

# MPC 概略

$$J = \frac{1}{2} [x_N^T P x_N] + \frac{1}{2} \sum_{i=0}^{N-1} [x_i^T Q x_i + u_i^T R u_i]$$

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix} = \begin{bmatrix} A \\ A^2 \\ \vdots \\ A^N \end{bmatrix} x_0 + \begin{bmatrix} B & 0 & \dots & 0 \\ AB & B & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N-1}B & A^{N-2}B & \dots & B \end{bmatrix} \underbrace{\begin{bmatrix} u_0 \\ u_1 \\ \vdots \\ u_{N-1} \end{bmatrix}}_U$$

- 1.  $J$  が最小になるような  $u_0^* \sim u_{N-1}^*$  を求める
  - 1.1 既知変数  $x_0$  から未知変数  $x_1 \sim x_N$  を推定
  - 1.2  $U$  についての最適化問題に変形
  - 1.3 最適化問題を解く
2.  $u_0^*$  をシステムへの入力とする

# $U$ についての最適化問題に変形 1

## 二次計画問題への変形

$$\begin{aligned} J &= \frac{1}{2} [x_N^T P x_N] + \frac{1}{2} \sum_{i=0}^{N-1} [x_i^T Q x_i + u_i^T R u_i] \\ &= \frac{1}{2} U^T H U + g(x_0)^T U + c(x_0) \end{aligned}$$

$c(x_0)$  は  $U$  が含まれていないので無視できる

評価関数が二次になっていることを利用する

二次の最適化関数を持つ問題は、一般に二次計画問題 (QP) として知られる

$$\begin{aligned} \min_x \quad & \frac{1}{2} x^T Q x + c^T x \quad \text{s.t. } A x \leq b \\ & G x = h \end{aligned}$$

## $U$ についての最適化問題に変形 2

$$U = \begin{bmatrix} u(0) \\ u(1) \\ \vdots \\ u(N-1) \end{bmatrix},$$

$$H = (B^T Q B + R),$$

$$Q = \begin{bmatrix} Q & & & \\ & \ddots & & \\ & & Q & \\ & & & P \end{bmatrix},$$

$$A = \begin{bmatrix} A \\ A^2 \\ \vdots \\ A^N \end{bmatrix},$$

$$g(x_0) = B^T Q A x_0,$$

$$R = \begin{bmatrix} R & & \\ & \ddots & \\ & & R \end{bmatrix}$$

$$B = \begin{bmatrix} B & 0 & \dots & 0 \\ AB & B & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ A^{N-1}B & A^{N-2}B & \dots & B \end{bmatrix}$$

$$c(x_0) = \frac{1}{2} x_0^T (A^T Q A + Q) x_0$$

# MPC 概略

$$J = \frac{1}{2} U^T H U + g(x_0)^T U + c(x_0)$$
$$U^* = \min_U J$$

- 1.  $J$  が最小になるような  $u_0^* \sim u_{N-1}^*$  を求める
  - 1.1 既知変数  $x_0$  から未知変数  $x_1 \sim x_N$  を推定
  - 1.2  $U$  についての最適化問題に変形
  - 1.3 最適化問題を解く
2.  $u_0^*$  をシステムへの入力とする



## 二次計画問題 (QP)

$$\begin{aligned} \min_x \quad & \frac{1}{2}x^T Qx + c^T x \quad \text{s.t.} \quad Ax \leq b \\ & Gx = h \end{aligned}$$

### KKT 条件

$$Qx + c - A^T \lambda - G^T \mu = 0$$

$$Ax - b = 0$$

$$Gx - h = 0$$

$$\mu \geq 0$$

$$\mu_i (Gx - h)_i = 0 \quad \text{for } i = 1, 2, \dots, m$$

- $\lambda$ : 等式制約の Lagrange 乗数ベクトル
- $\mu$ : 不等式制約の Lagrange 乗数ベクトル

KKT 条件を満たす解を見つけばいい!!!!

# MPC(線形) で重要なのは二次計画法

数値計算を用いて KKT 条件を満たす解を求める

Newton 法	制約条件が無い or 等式制約のみ の凸最適化
有効制約法	比較的小規模 ~ 中規模 の凸最適化
内点法	大規模 な凸最適化

凸関数で制約が凸集合 → 最適化問題の解が大域的最適解

どの手法で二次計画問題を解くのかで MPC の性能が決まる!!!

# Newton 法 1

$$\min_x f(x) \quad \text{s.t.} \quad g(x) = 0$$

Lagrange 関数を  $L(x) = f(x) + \lambda^T g(x)$  と定義すると,  
最適解の必要条件は次式となる

$$\nabla L(x) = 0$$

最適解の十分条件はヘッセ行列  $\nabla^2 f(x)$  が正定値

## Newton 法の Point

$\nabla L(x) = 0$  の連立方程式を解くのは困難



更新式  $x_{k+1} = x_k + d$  を用いて  $\nabla L(x) = 0$  を解く

# Newton 法 2

$$\nabla L(x) = 0 \quad \text{更新式: } x_{k+1} = x_k + d$$

- $\nabla L(x_k + d)$  を Taylor 展開をする

$$\nabla L(x_k + d) \simeq \nabla L(x_k) + \nabla^2 L(x_k) d$$

- $\nabla L(x) = 0$  では  $\nabla L(x_k + d)$  が 0 になる


$$\nabla L(x_k) + \nabla^2 L(x_k) d = 0 \iff d = -\nabla^2 L(x_k)^{-1} \nabla L(x_k)$$

## Newton 法

1. 初期点  $x_0$  を定め、 $k = 0$  とする
2.  $\|\nabla L(x_k)\|$  が十分に小さければ終了
3.  $x_{k+1} = x_k - \nabla^2 L(x_k)^{-1} \nabla L(x_k)$

# 内点法

- 不等式制約を持つ凸最適化問題を解ける
- 主双対内点法は主内点法よりも高速
- ベースはニュートン法



# 主内点法 1

## 主内点法の Point

不等式制約があると最適化が難しくなる

$$\begin{aligned} \min_x f(x) \quad & \text{s.t. } g(x) = 0 \\ & x \geq 0 \end{aligned}$$

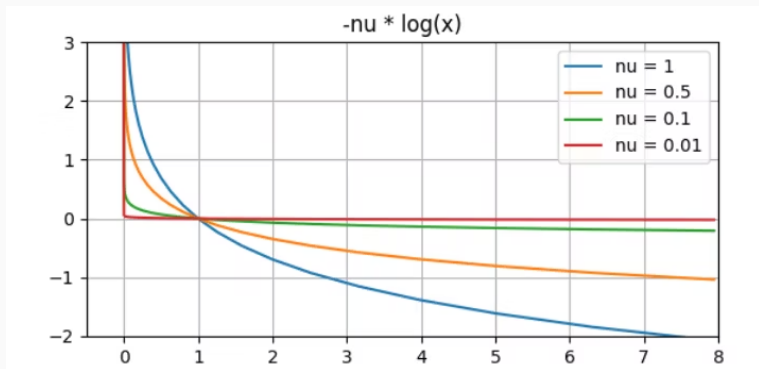


バリア関数 によって不等式制約を最小化する関数に含める

$$\min_x f(x) - \nu \sum_{i=1}^I \log(x_i) \quad \text{s.t. } g(x) = 0$$

等式制約のみになったので **Newton** 法で解ける!!!

## 主内点法 2



モデル予測制御 (MPC) による軌道追従制御より

- 初期点として実行可能な点を与える必要がある
- 制約の境界付近では Newton 法の数値計算が解けない場合もある

# 主双対内点法 1

$$\min_x \frac{1}{2} x^T Q x + c^T x \quad \text{s.t. } Ax = b, x \geq 0$$

$$Ax = b, \quad x \geq 0$$

$$A^T \lambda + \mu = Qx + c, \quad \mu \geq 0$$

$$x^T \mu = 0$$

$x, \lambda, \mu$  全てに対してニュートン法を行う

$$x_{k+1} = x_k + dx$$

$$\lambda_{k+1} = \lambda_k + d\lambda$$

$$\mu_{k+1} = \mu_k + d\mu$$



## 主双対内点法 2

$$Ax = b$$

$$A^T \lambda + \mu = Qx + c$$

$$x^T \mu = 0$$

- Newton 法と同様に扱う変数  $(x, \lambda, \mu)$  を一次近似する ( $dXd\mu = 0$ )

$$A(x_k + dx) = b$$

$$A^T(\lambda + d\lambda) + (\mu_k + d\mu) = Q(x_k + dx) + c$$

$$X_k \mu_k + X_k d\mu + \mu_k dX = 0$$

- 通常の Newton 法はここで  $dx, d\lambda, d\mu$  についてまとめる
- 主双対内点法はここで中心パスを導入し、これに沿った解を得ることで最適解に近づく

$$X_k \mu_k + X_k d\mu + \mu_k dX = \sigma \nu_k = \sigma \frac{1}{N} \sum_i (x_i \mu_i)^k$$

# 主双対内点法 3

## 主双対内点法

$$\begin{bmatrix} A & 0 & 0 \\ -Q & A^T & I \\ M_k & 0 & X_k \end{bmatrix} \begin{bmatrix} dx \\ d\lambda \\ d\mu \end{bmatrix} = \begin{bmatrix} b - Ax_k \\ Qx_k + c - A^T\lambda_k - \mu_k \\ \sigma\nu_k e - X_k\mu_k \end{bmatrix},$$

$$X_k = \text{diag}(x_{k1}, \dots, x_{kn}),$$

$$M_k = \text{diag}(\mu_{k1}, \dots, \mu_{kl}),$$

$$e = [1, \dots, 1]^T.$$


- Newton 法と同様、更新式として解く
- 初期値として実行可能な点 (内点) を与える必要がある

# MPC 概略

$$J = \frac{1}{2} U^T H U + g(x_0)^T U + c(x_0)$$
$$U^* = \begin{bmatrix} u^*(0) \\ u^*(1) \\ \vdots \\ u^*(N-1) \end{bmatrix} = \min_U J$$

- 1.  $J$  が最小になるような  $u_0^* \sim u_{N-1}^*$  を求める
  - 1.1 既知変数  $x_0$  から未知変数  $x_1 \sim x_N$  を推定
  - 1.2  $U$  についての最適化問題に変形
  - 1.3 最適化問題を解く
2.  $u_0^*$  をシステムへの入力とする

# MPC のイメージ



モデル予測制御 (MPC) による軌道追従制御より

# 参考資料

## 書籍

- しっかり学ぶ数理最適化

## サイト (URL)

- MyEnigma の MPC 導入:  
<https://myenigma.hatenablog.com/entry/2016/07/25/214014>
- MyEnigma の MPC 数式:  
<https://myenigma.hatenablog.com/entry/2017/02/07/084922>
- MPC の具体例:  
<https://ramune6110.hatenablog.com/entry/2022/02/13/154405>
- MPC を用いた倒立振子:  
<https://qiita.com/slowsingle/items/f3074ea6670da42696e0>
- MPC の説明と実機を用いた実験:  
<http://www.kostasalexis.com/linear-model-predictive-control.html>